

T2.1.C · Ejecutores reales con guardrails

Owner: Celestino · Branch `pr/t2.1.c-real-executors-guardrails` · base `main@019492c` · LLM real para LOW/MEDIUM internas · guardrails T2.1.A intactos

Status: PR listo para revisión. **812/812** pytest · **35/35** vitest · **tsc 0 errores**. Los 10 ejecutores LOW/MEDIUM ahora producen output útil real (LLM via DeepSeek/Haiku) con fallback determinístico mejorado. **HIGH y CRITICAL siguen bloqueados** · ningún envío externo real ocurre. Sin merge · sin deploy.

1. Resumen ejecutivo

El Action Center pasaba listas vacías y esqueletos placeholder. T2.1.C conecta el cliente LLM existente del proyecto (`agent/llm.py` · DeepSeek con fallback Haiku) a los 10 ejecutores LOW y MEDIUM. Cada uno tiene system prompt versionado, validación estricta del output, truncado por formato y fallback determinístico mejorado si el LLM no está disponible.

- **HIGH siguen sin ejecutor:** `enviar_mensaje_whatsapp` / `enviar_campana_masiva` / `publicar_red_social` / `contactar_lead` explícitamente NO se mapean en `EJECUTORES_T21A`. `ejecutar_accion` los rechaza con mensaje 'futuro PR'.
- **CRITICAL siguen bloqueados:** el flag `esta_bloqueado_t21` intercepta antes de cualquier ejecutor · `audit action_blocked_critical`.
- **Sanitización doble:** el contexto del perfil pasa por `construir_contexto_perfil` que cap cada campo a 400 chars y omite vacíos · el output del LLM se valida (JSON shape · trunca por formato · longitud máxima por campo).
- **Audit log enriquecido:** cada ejecución registra `action_completed` con `modo` (llm|fallback) y `provider` (llm|fallback) sin filtrar el output crudo.
- **Sin gasto real de créditos:** T2.1.C usa el LLM directo vía `agent/llm.py` · sin reservas/descuentos. T2.1.D es el PR específico de billing.

2. Causa / objetivo

Tras T2.1.A + T2.1.B el Action Center funciona estructuralmente · lifecycle de acciones, permisos, audit log, dashboard. Pero los ejecutores entregaban placeholder strings · útiles para validar el flow, inútiles para el usuario final. El objetivo de T2.1.C es cerrar esa brecha sin abrir riesgo: dar valor real a las acciones LOW/MEDIUM internas (generación de texto), manteniendo los guardrails que ya nos hicieron rechazar HIGH/CRITICAL.

3. Archivos modificados

Archivo	Tipo	Cambio
<code>agent/automation/prompts.py</code>	NEW	10 system prompts versionados · 1 por ejecutor · <code><i>construir_contexto_perfil()</code>
<code>agent/automation/execution.py</code>	MOD	10 ejecutores reescritos para usar <code>agent/llm.py</code> + fallback. Helpers <code><i>_llm_completar()</code>
<code>tests/test_automation_executors_real.py</code>	NEW	25 tests pytest · LLM mocked · cubre cada ejecutor happy path · fallback · vali
<code>tests/test_automation_execution.py</code>	MOD	Test T2.1.A actualizado: modo ahora es 'llm' 'fallback' (antes 'dry_run'). +1 línea.

4. Ejecutores conectados

LOW (auto-ejecutables) · 5 ejecutores

tipo_accion	Output del LLM	Fallback
generar_plan_semanal	Markdown · 5-7 acciones por día	Esqueleto basado en perfil · 5 días + Próximo paso
generar_calendario_contenido	JSON array 7 días · titulo · copy · formato · canal	JSON 7 días con formatos rotados · canal del perfil
generar_checklist_ventas	Markdown checklist 8-12 items imperativos	8 items predefinidos accionables esta semana
analizar_diagnostico	JSON · completitud · fortalezas · oportunidades · desafíos · áreas de oportunidad	JSON · completitud · recomendación según %
generar_idea_oferta	JSON 3 alternativas · titulo · descripcion · por_QUE · alternativa si es gratis	3 alternativas si es gratis (paquete inicial · recurrente · bundle)

MEDIUM (preparan · NO envían) · 5 ejecutores

tipo_accion	Output del LLM	Fallback
preparar_mensaje_whatsapp	Borrador texto · placeholder {NOMBRE} · max 600 chars	Borrador genérico cálido · placeholder {NOMBRE}
preparar_campana_whatsapp	JSON 3 mensajes (anuncio · recordatorio · cierre)	3 mensajes genéricos por día (1, 3, 5)
preparar_publicacion_redes	JSON copy · hashtags · formato · CTA	Copy reflexivo · 2 hashtags · post · CTA pregunta
preparar_email_seguimiento	JSON asunto + cuerpo · max 800 chars	Email cálido genérico · placeholder {NOMBRE}
borrador_copy_oferta	JSON titulo + copy_largo + 2 variantes A/B	Copy genérico + 2 variantes simples

Cada output MEDIUM incluye **estado_envio: 'pending_user_review'** y un campo **aviso** que recuerda al usuario que es solo borrador. El componente UI ya muestra esos resultados en el Action Center.

5. Proveedor LLM usado

Reusa el cliente existente `agent/llm.py` que ya viene en el proyecto desde antes (lo usan emotion, learning, location, onboarding, contenido):

- **Primario** • **DeepSeek** (`deepseek-chat`) • barato y rápido para tareas de generación. API key en `DEEPSEEK_API_KEY`.
- **Fallback** • **Claude Haiku 4.5** (`claude-haiku-4-5-20251001`) • si DeepSeek falla. API key en `ANTHROPIC_API_KEY`.
- **Ambos con timeout corto y manejo de excepciones.** Si los dos fallan, `completar_con_sistema()` retorna None y el ejecutor cae a su fallback determinístico.
- **NO se introdujo un nuevo cliente LLM.** Esto evita duplicar config, env vars y fees • respeta la convención del proyecto.

Si en el futuro se quisiera modelo distinto (Sonnet, Opus) para alguna acción específica, se haría en otro PR • `agent/llm.py` se extiende sin tocar T2.1.C.

6. Tests ejecutados

pytest • 812/812 passing (787 base + 25 nuevos T2.1.C) • 173s.
vitest • 35/35 passing (sin cambios desde T2.1.B hotfix).
tsc • 0 errores • build no necesita rebuild (solo backend cambió).

Tests T2.1.C nuevos • 25

Clase	Tests	Cubre
TestContextoSanitizado	3	Perfil vacío → placeholder • campos vacíos omitidos • trunca a 400 chars
TestEjecutorPlanSemanal	2	LLM responde → modo=llm • LLM None → fallback útil (no placeholder)
TestEjecutorCalendarioContenido	3	JSON array • JSON con fences ``json • JSON inválido → fallback
TestEjecutorChecklistVentas	2	LLM markdown lista parsea • fallback ≥8 items
TestEjecutorAnalizarDiagnostico	2	LLM JSON dict • fallback calcula completitud local
TestEjecutorIdeaOferta	1	Fallback con 3 alternativas estructuradas
TestEjecutorPreparMensajeWhatsApp	2	MEDIUM sin aprobar → falla • aprobado → completed con estado_envio=pending_us
TestEjecutorPreparPublicacionRedes	1	Aprobado → estado_publicacion=pending_user_review
TestEjecutorPreparEmailSeguimiento	1	Genera asunto + cuerpo • estado_envio=pending_user_review
TestEjecutorPreparCampanaWhatsApp	1	3 mensajes • estado_envio=pending_user_review
TestEjecutorBorradorCopyOferta	1	Copy + 2 variantes A/B
TestGuardrailsHigh	3	3enviar_mensaje_whatsapp • publicar_red_social • contactar_lead aprobados → fa
TestGuardrailsCritical	1	1envio_masivo_clientes aprobado → bloqueado
TestEjecutoresNoUsanProvidersReales	1	1Inspecciona source de los 10 ejecutores • prohibido whapi/twilio/stripe./providers/
TestAuditLogModoYProviderEnPayload	1	1action_completed payload incluye modo=llm provider=llm • telefono completo NO

7. Riesgos

Riesgo	Severidad	Mitigación
LLM puede inventar datos del cliente	Bajo · UX	System prompts EXPLÍCITAMENTE prohíben inventar nombres propios · usan {NOMBRE}
LLM puede generar texto en idioma incorrecto	Bajo	System prompts piden español explícito · perfil del usuario (MX/CO/AR/EU/US) y idioma
JSON malformado del LLM	Bajo	<code><i>_parsear_json_seguro()</code> <code></i></code> tolera fences ``json y prosa alrededor · si falla, cae a excepción
Costo LLM si el usuario abusa de 'Generar acciones' · billing	Medio	Idempotencia ya existente (<code>idempotency_key sha256(tel tipo playbook opp fecha)</code>)
LLM filtra PII si el usuario la incluye en el perfil	Bajo · CCPA	<code><i>construir_contexto_perfil()</code> <code></i></code> trunca a 400 chars/campo. El audit log NO loguea PII
Race condition aiosqlite en pytest workers	Cero · solo dev	Issue conocido · re-run pasa consistente.

8. Out of scope · NO entra en T2.1.C

- **Ejecutores HIGH reales** (envío real WhatsApp/Twilio/email/publicaciones redes) · explícitamente excluidos · esperan T2.1.D o futuro PR con guardrails reforzados (TCPA, opt-in, rate-limit, reembolso si falla).
- **Desbloquear CRITICAL** · explícitamente excluido. Requiere confirmación reforzada (2FA owner · cooldown timer · etc).
- **Reservas/descuento de créditos** · T2.1.D. T2.1.C estima costo en `costo_creditos_estimado` pero no descuenta nada.
- **Streaming de respuestas LLM** · respuestas son one-shot · el usuario espera ~3-10s y ve el resultado. Streaming sería futuro PR con SSE o websocket.
- **Caché de LLM** · cada 'Ejecutar' llama al LLM. Si la acción ya fue ejecutada, su `result_json` se conserva en DB · pero re-ejecutar pide al LLM de nuevo.
- **Métricas de calidad del LLM** (eval framework) · futuro.
- **Refinar prompts con feedback del usuario** (thumbs up/down) · futuro · T2.1.E quizás.

9. Siguiente PR recomendado · T2.1.D

T2.1.D · Reservas y descuento real de créditos · audit extendido:

- Reservar créditos al iniciar ejecución (transaccional con la transición a 'running').
- Descontar al completar · reembolsar al fallar (transición → failed o → cancelled).
- Ajustar costo estimado vs real (tokens consumidos via LLM response.usage si el SDK lo expone).
- Pruning del audit log · retención configurable.
- Dashboard métrica: 'créditos consumidos por automation este mes'.
- **NO desbloquear CRITICAL ni HIGH reales en T2.1.D** · esos esperan PR específico de cada vertical (envío WhatsApp · publicación redes · etc) con sus guardrails dedicados.

10. Instrucciones para abrir PR

Campo	Valor
URL	github.com/celestinojbm/Dona-agent/pull/new/ pr/t2.1.c-real-executors-guardrails
Título sugerido	feat(automation): ejecutores reales con guardrails (T2.1.C)
Base	main

Head	pr/t2.1.c-real-executors-guardrails
Body markdown	Generado abajo · listo para copiar/pegar

11. Body markdown del PR (copy-paste)

Resumen

Conecta los 10 ejecutores LOW/MEDIUM del Action Center al cliente LLM existente del proyecto (agent/llm.py · DeepSeek + fallback Claude Haiku). Los ejecutores ahora producen output útil real (plan semanal, calendario contenido, checklist, mensajes WA, borradores copy, etc.) en lugar de placeholders.

Guardrails T2.1.A intactos:

- LOW pending → ejecuta auto
- MEDIUM/HIGH → requieren aprobación
- HIGH (enviar_*, publicar_*, contactar_lead) → SIN ejecutor · ejecutar_accion los rechaza con mensaje 'futuro PR'
- CRITICAL → bloqueado · audit action_blocked_critical

Cero envíos externos reales. Cero gasto de créditos reales (T2.1.D agrega reservas).

Cambios

- agent/automation/prompts.py (NEW) · 10 system prompts versionados · construir_contexto_perfil() sanitiza y trunca a 400 chars/campo · omite vacíos.
- agent/automation/execution.py · 10 ejecutores reescritos. Helpers _llm_completar(), _parsear_json_seguro() (tolera fences ``json), _trunc(). Audit log action_completed incluye modo y provider.
- tests/test_automation_executors_real.py (NEW) · 25 tests con LLM mocked.
- tests/test_automation_execution.py · ajuste de assert modo='dry_run' → 'llm'|'fallback' (+1 línea).

Provider LLM

Reusa agent/llm.py existente · DeepSeek primario + Claude Haiku fallback. NO se introduce cliente nuevo. Si LLM no responde (env vars faltantes o errores), cada ejecutor cae a fallback determinístico mejorado (no placeholders inútiles).

Tests

- pytest tests/test_automation_executors_real.py · 25/25 passing · 17s
- pytest suite completa · 812/812 passing · 173s · cero regresiones
- vitest · 35/35 passing (sin cambios)
- npx tsc --noEmit · 0 errores

Tests específicos verifican:

- Cada ejecutor LLM happy path → modo=llm
- LLM None → fallback determinístico útil
- JSON con fences ``json se parsea
- HIGH (enviar_mensaje_whatsapp · publicar_red_social · contactar_lead) aprobados → failed con 'futuro PR'
- CRITICAL aprobado → bloqueado · audit action_blocked_critical
- Source de los 10 ejecutores NO contiene whapi/twilio/stripe./providers/send_message/enviar_mensaje/publish_/post_to_*
- Audit payload tiene modo+provider · sin telefono completo
- construir_contexto_perfil omite vacíos y trunca a 400 chars

Sin cambios de

- env vars · agent/llm.py ya leía DEEPSEEK_API_KEY y

```
ANTHROPIC_API_KEY (presentes en Render)
- modelos DB · audit log usa columnas existentes
- endpoints HTTP · /api/automation/* sin cambios
- componente UI · seccion-action-center.tsx sin cambios
  (renderiza el result_json más útil automáticamente)

## Out of scope

- Ejecutores HIGH reales (envío WhatsApp/email/posts) · futuros
  PRs con guardrails dedicados (TCPA, opt-in, rate-limit)
- Desbloquear CRITICAL · futuro · requiere 2FA + cooldown
- Reservas/descuento real créditos · T2.1.D
- Streaming respuestas · caché LLM · eval framework
- Refinar prompts con feedback usuario

## Plan post-merge

1. Render auto-redeploy ~2 min · ejecutores ya activos.
2. Smoke en dashboard:
  - usuario premium con perfil completo · botón 'Generar
    acciones' · ver acciones generadas
  - 'Ejecutar' una LOW (generar_plan_semanal) · ver plan
    real en markdown en la card 'Resultado'
  - aprobar y ejecutar una MEDIUM (preparar_mensaje_whatsapp)
    · ver borrador real
3. Verificar Vercel/Render logs · debería aparecer
  '[AUDIT-AUT] ... evento=action_completed riesgo=low ...'
  con modo=llm en el payload sanitizado.
```

Branch pushed · sin merge. Espera tu review en GitHub. Yo no mergeo nada hasta tu OK explícito.